

Alex' Projekt — Firmenbuch-Recherche mit Browser-Automatisierung

Ziel: Eine österreichische Firma auf **openfirmenbuch.at** suchen, den Browser **sichtbar** öffnen, **Screenshots** machen und **alle veröffentlichten Jahresabschluss-PDFs herunterladen** — vollständig automatisiert und in einem neuen Chatfenster exakt reproduzierbar.

Dieses Dokument beschreibt: **was** genutzt wurde, **wie**, **warum**, **was nicht funktioniert hat**, und liefert die fertigen Skripte + einen **Copy-&-Paste-Prompt** für ein neues Chat.

1. Endergebnis (Beispiel Velartis GmbH)

- Browser (Chromium) öffnet openfirmenbuch.at, sucht „Velartis GmbH“, öffnet die Detailseite.
- Screenshots: Startseite, Eingabe, Suchergebnis, Detailseite.
- **12 Jahresabschluss-PDFs (2014–2024)** heruntergeladen und lesbar umbenannt:

Velartis_GmbH_Jahresabschluss_2024_eingereicht_2025-06-04.pdf usw.

- Daraus erstellt: Kennzahlen-CSV, Analyse-Markdown und **Analyse-PDF**.

Alles reproduzierbar über die beiden Skripte in diesem Ordner.

2. Voraussetzungen / Umgebung

Komponente	Status auf diesem PC	Hinweis
Betriebssystem	Windows 11	
Node.js	C:\Program Files\nodejs\node.exe (im PATH)	node -v zum Prüfen
Playwright	@playwright/test ist im Projekt core-app installiert	wird von hier aus mitgenutzt
Browser	Chromium (ms-playwright-Cache, chromium-1217)	bereits installiert
Shell	PowerShell oder Git-Bash	beide funktionieren

Wichtig — woher kommt Playwright: Beide Skripte laden Playwright über einen kleinen Resolver (`loadChromium()`): **zuerst aus diesem Repo** (`./node_modules` , sobald `npm install` gelaufen ist), **sonst aus dem Projekt core-app** auf diesem PC. So läuft es sowohl frisch geklont als auch auf der ursprünglichen Maschine.

> Empfohlen nach dem Klonen des Repos (macht es unabhängig von core-app): > `powershell > npm install > npx playwright install chromium >` > Der Fallback-Pfad auf core-app steht direkt in `loadChromium()` in beiden `.mjs` -Dateien und kann bei Bedarf angepasst werden.

3. Schnellstart (so wird es benutzt)

PowerShell im Ordner `alex's projekt` öffnen (im Explorer in die Adressleiste `powershell` tippen) und:

`powershell`

Firma suchen, Browser SICHTBAR, alle Jahresabschlüsse herunterladen

`node "firmenbuch-suche.mjs" "Velartis GmbH"`

Nur Suche + Screenshots, ohne Downloads

`$env:NO_DOWNLOAD=1; node "firmenbuch-suche.mjs" "Firma XY GmbH"; Remove-Item Env:NO_DOWNLOAD`

Schnell & unsichtbar (kein Fenster) – z.B. für Tests

\$env:HEADLESS=1; node "firmenbuch-suche.mjs" "Velartis GmbH"; Remove-Item Env:HEADLESS

Ergebnisse landen unter alexs projekt\output\Firmenname\ (Screenshots 01 – 04, PDFs, _stammdaten.txt, _ergebnis.txt).

Output als PDF erzeugen (z.B. aus einer Markdown-Zusammenfassung): powershell node "report-pdf.mjs" "meine-analyse.md" "Analyse.pdf"

4. Genauer Ablauf — was, wie, warum

Schritt 0 — Werkzeugwahl. Zuerst geprüft, ob ein **Playwright-MCP-Server** verfügbar ist (wäre der direkteste Weg, den Browser zu steuern). War **nicht** vorhanden → stattdessen das **Playwright-npm-Paket** über kurze Node-Skripte genutzt. Warum Playwright: zuverlässige Browsersteuerung inkl. **Download-Handling** und Screenshots; bereits im Projekt installiert.

Schritt 1 — Umgebung verifiziert. node, Edge und der Chromium-Cache geprüft, bevor irgendetwas läuft (spart Fehlversuche).

Schritt 2 — Suche. https://openfirmenbuch.at geöffnet, Suchfeld (input[placeholder*="Firmennamen"]) befüllt, Enter. Ergebnisseite-URL: .../results/?query=<Firma>&page=1.

Schritt 3 — Treffer öffnen. Auf die Firmenkarte geklickt → Detailseite .../company/?fnr=<FN>. Die Karten sind **keine <a>-Links**, sondern per JavaScript klickbar → man muss den Text/Heading klicken, nicht eine URL aufrufen.

Schritt 4 — Screenshots + Stammdaten. Vollseiten-Screenshot der Detailseite, Stammdaten-Text gesichert (Adresse, Geschäftsführer, FN, Kennzahlen).

Schritt 5 — Dokumente herunterladen. Im Block „Firmendokumente“ gibt es je Zeile einen „Herunterladen“-Button. Per page.getByRole('button',{name:/Herunterladen/i}) alle gefunden, nacheinander geklickt und das Playwright- **download -Event** abgefangen (page.waitForEvent('download') → download.saveAs(...)). Die Tabelle ist **paginiert** (Buttons „1“, „2“, ...) → Folgeseiten anklicken und erneut abarbeiten.

Schritt 6 — Umbenennen. Die Original-Dateinamen vom Server sind kryptisch (document_422436_0070752521244_..._PDF.pdf). Aus der Tabellenzeile wird **Geschäftsjahr + Einreichdatum** geparkt → lesbarer Name ..._Jahresabschluss_2024_eingereicht_2025-06-04.pdf.

Schritt 7 — Inhalte auslesen. Die PDFs sind **maschinenlesbar** (Textebene). Sie wurden direkt gelesen; jeder Abschluss zeigt das **laufende Jahr in EUR** und das **Vorjahr in TEUR**. Daraus Kennzahlen + Trend rekonstruiert (Jahresergebnis = Bilanzgewinn – Gewinnvortrag).

Schritt 8 — Output als PDF. HTML gebaut und über Chromium page.pdf({format: 'A4'}) gerendert (kein Office/PDF-Tool nötig). Siehe report-pdf.mjs.

5. Wichtige Erkenntnisse über openfirmenbuch.at

- **Suchfeld-Platzhalter:** „Geben Sie den Firmennamen ein...“
- **Ergebnis-URL:** .../results/?query=<text>&page=1 — „Keine Ergebnisse gefunden“ bei Falschschreibung.
- **Detail-URL:** .../company/?fnr=<Firmenbuchnummer> (z.B. 422436f).
- **Status-Filter** (Aktiv/Historisch/Gelöscht) sind standardmäßig **alle** an.
- **Dokumente:** Tabelle „Firmendokumente“, Spalten Datum/Typ/Datei/Aktionen, je Zeile „Anzeigen“ + „Herunterladen“, **paginiert** (10 pro Seite).
- **Finanz-Tabs (Jahre 2024–2020)** auf der Detailseite zeigen **immer nur den zuletzt ausgewerteten Jahrgang** (hier 2024) — **kein** verlässlicher Verlauf! Historische Zahlen stehen **nur in den PDFs**.
- **Kleinst-/Klein-GmbHs legen nur die Bilanz offen — keine GuV** → kein Umsatz/keine Marge im Firmenbuch.

6. Was NICHT funktioniert hat / Schwierigkeiten (chronologisch)

#	Problem	Ursache	Lösung
1	Kein Playwright-MCP	nicht installiert	Playwright-npm-Paket per Node-Skript genutzt

2	„Verlartis GmbH“ → 0 Treffer	Tippfehler im Firmennamen	Richtige Schreibweise Velartis → 1 Treffer. <i>Lehre: Schreibweise zählt.</i>	
3	Kryptische Download-Dateinamen	Server liefert interne Namen	aus Tabellenzeile Jahr+Datum geparkt und umbenannt	
4	Umbenennen schlug fehl (ENOENT)	Dateiname enthält <code>:</code> (unter Windows verboten)	Zeichen <code>` < > : " / \ \</code>	? * aus Namen entfernen
5	Großes HTML im Bash- Heredoc → „unexpected EOF“	Sonderzeichen/Quotes im Heredoc	Skript als <code>.mjs</code> -Datei schreiben und mit <code>node datei.mjs</code> ausführen	
6	Nullbyte in geschriebener <code>.mjs</code>	Leerzeichen in einer Regex-Zeichenklasse wurde fehlerhaft gespeichert	Leerzeichen aus Zeichenklassen heraushalten; mit <code>node --check</code> prüfen	
7	Skript findet Playwright nicht (außerhalb von core-app)	ESM sucht <code>node_modules</code> ab Skript-Ordner, nicht ab cwd	<code>createRequire(<core-app/package.json>)</code> als Anker → läuft von überall	
8	Kein Finanz-Verlauf auf der Website	Seite wertet nur den neuesten Abschluss aus	Verlauf direkt aus den heruntergeladenen PDFs gelesen	

7. Dateien in diesem Ordner

Datei	Zweck
firmenbuch-suche.mjs	Hauptskript: Suche → Screenshots → Download aller Jahresabschlüsse
report-pdf.mjs	Wandelt Markdown/HTML in ein formatiertes PDF (via Chromium)
README.md	Diese Anleitung
Anleitung.pdf	PDF-Version dieser Anleitung
NEUER-CHAT-PROMPT.txt	Fertiger Text zum Einfügen in ein neues Chatfenster
output\<Firma>\	Ergebnisse je Firma (Screenshots, PDFs, Stammdaten)

8. Prompt für ein NEUES Chatfenster (kopieren & einfügen)

> Öffne mit Playwright sichtbar den Browser, gehe auf openfirmenbuch.at und suche „<FIRMENNAME> GmbH“. Öffne den ersten Treffer (Detailseite), mach Screenshots und lade **alle** Jahresabschluss-PDFs herunter (auch Folgeseiten der Dokumententabelle), benenne sie lesbar nach `Firma_Jahresabschluss_<Jahr>_eingereicht_<JJJJ-MM-TT>.pdf`. > > Nutze das fertige Skript: führe in PowerShell aus > `node "C:\Users\Leonie\OneDrive - Fachschule für Sozialberufe\Desktop\alexs projekt\firmenbuch-suche.mjs" "<FIRMENNAME> GmbH"`. > Die Ergebnisse liegen dann in `...\alexs projekt\output\<Firma>\`. > > Danach: lies die PDFs aus, erstelle eine Zusammenfassung mit allen Bilanz-Kennzahlen und Trend, und gib mir das Ergebnis **als PDF** (z.B. via `report-pdf.mjs`). Achte auf: korrekte Schreibweise des Firmennamens (sonst 0 Treffer), keine `:` /Sonderzeichen in Dateinamen, kleine GmbHs haben **keine GuV** (nur Bilanz).

Erstellt am 13.06.2026. Datenquelle: öffentliche Firmenbuch-Auszüge über openfirmenbuch.at.